ChatGPT

Resumen Ejecutivo Científico

Presentamos una arquitectura de carga útil de **microscopía computacional** para CubeSat 3U en LEO, capaz de procesar imágenes microscópicas a bordo y transmitir solo resultados cuantitativos. El objetivo es superar las **limitaciones de ancho de banda y potencia** del satélite enviando únicamente telemetría (metadatos) en lugar de imágenes completas. Para ello combinamos técnicas de **Fourier Ptychographic Microscopy (FPM)** con *Edge AI* y un sistema dual de procesamiento ("degradación elegante"). El hardware clave incluye un Raspberry Pi Compute Module (CPU+eMMC) en una tarjeta base personalizada, una cámara CMOS (p.ej. Raspberry Pi Camera OV5647 u otra MIPI de 5–12 MP) y una matriz de LEDs tipo *Unicorn HAT HD* (matriz 16×16 de LED). Bajo funcionamiento nominal, la instrumentación captura múltiples imágenes con iluminación estructurada y las reconstrute en alta resolución (≤1 μm) mediante algoritmos iterativos o de aprendizaje profundo. Luego usa un modelo de segmentación IA (p.ej. **Cellpose** u **Omnipose**) para detectar células o fibras, extrayendo medidas (áreas, longitudes, rupturas, etc.) con precisión sub-micrométrica. En condiciones de estrés térmico/radiación, el sistema se degrada al modo de bajo consumo: apaga la IA y aplica métodos clásicos de visión por computadora (transformada de Hough, watershed, etc.), ahorrando hasta ~80% de ciclos de CPU.

Este enfoque está respaldado por antecedentes espaciales: por ejemplo, la NASA desarrolló un prototipo portátil de FPM que integra una cámara Pi de 8 MP, matriz de LEDs y un Jetson Nano para cómputo *on-edge* [1]. Además, misiones como **Astro Pi** usan Raspberry Pi 4 con acelerador Coral TPU en la ISS, confirmando la viabilidad de inferencia en borde con SoCs comerciales [2]. Para validación se propone una **matriz de pruebas** con imágenes reales (frotis sanguíneos, fibras de algodón/Kevlar) y generadas (ruido simulado), usando conjuntos de datos públicos (p.ej. *BBBC* [3]). Se emplearán métricas estándar (IoU, precisión, error en μm, tiempo, consumo) para comparar pipeline IA vs. CV en escenarios nominales y degradados. Como muestra la siguiente figura (dispositivo FPM de la NASA), todos los componentes encajan en un volumen ~30×10×10 cm con consumo total típico de <10–15 W en proceso intensivo.

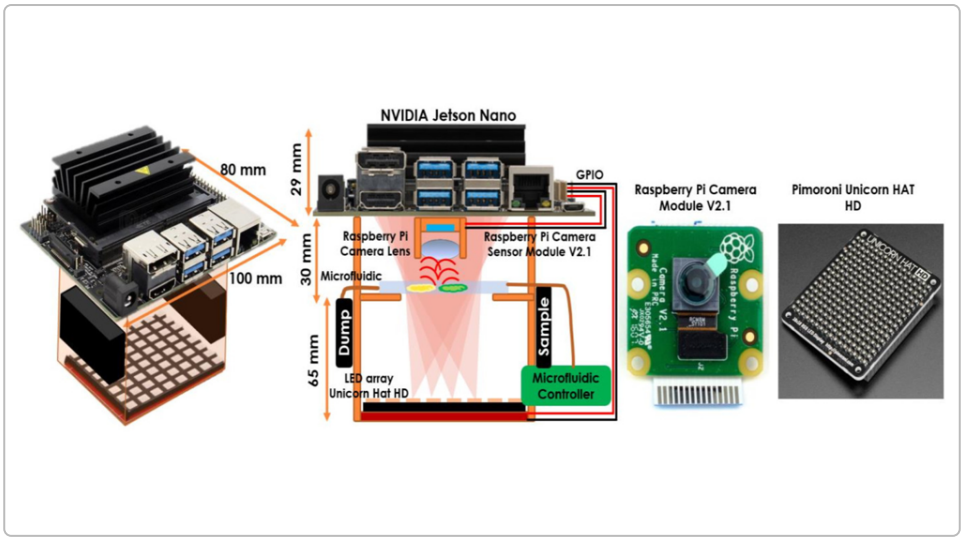

*Figura – Prototipo portátil de FPM de la NASA, con matriz de LEDs (*Unicorn HAT*), cámara Raspberry Pi y NVIDIA Jetson Nano como procesador AI integrado* [1].

1. Objetivos Científicos y Casos de Uso

- **Biomedicina (Frotis sanguíneo):** Analizar cultivos de células sanguíneas en microgravedad. Se cuenta células rojas y blancas, detecta agregados/clumps. En LEO, la microgravedad altera el crecimiento y expresión génica celular [4], por lo que es crucial evaluar en vuelo cómo cambian morfologías o aglomeraciones celulares. El uso de IA (Cellpose/Omnipose) permite separar células superpuestas con precisión (human-level) [5] [6], mientras que métodos clásicos fallarían en fenotipos complejos.

- **Ciencia de Materiales (Fibras/Algodón/Polímeros):** Estudiar la degradación estructural (microfrácturas, cambio de grosor, rupturas) en tejidos y polímeros expuestos a radiación UV, oxígeno atómico y ciclos térmicos de LEO. Las fibras son estructuras largas y delgadas; su caracterización requiere alta resolución y calibración continua. Aquí OpenCV (p. ej. transformada de Hough para líneas, detección de bordes) puede extraer eficientemente longitud y ángulos de fibra con mínimo consumo, mientras que IA podría segmentar geometrías más complejas (fibra torcida, daño difuso).

En ambos casos se busca medir parámetros: **conteos, áreas, perímetros, orientación, índice de daño**, etc., con precisión de laboratorio. La metrología óptica in-situ (ver sección 5) calibra escalas en tiempo real para que el satélite entregue datos científicos útiles y cuantitativos.

2. Matriz de Pruebas y Validación (Protocolos)

Se propone un banco de pruebas exhaustivo con tres tipos de muestras:

- **Escenario Nominal (Control):** 5–10 imágenes *ideales* (células bien separadas, alta iluminación, flujo uniforme; fibras alineadas y nítidas). Establecen el punto de referencia. Se comprobará que la precisión geométrica (áreas, longitudes) alcance ≈95–98% con IA y ≥85–90% con métodos clásicos. Estas imágenes sirven para afinar calibración y demostrar que *ambos* pipelines funcionan correctamente bajo condiciones favorables.

- **Alta Densidad (Desafío biológico):** 5–10 imágenes con células muy juntas, solapadas, en división, o tejidos fibrilares cruzados. Aquí los métodos clásicos (threshold+Watershed) suelen fusionar objetos contiguos, mientras que la IA puede separar bordes complejos. Se analizará cómo el **IoU** (Jaccard) de la segmentación y la precisión de conteo difieren. Este caso justifica el uso de IA *on-board*: se espera que Cellpose/Omnipose mantenga IoU alto (>0.8) donde OpenCV baja notablemente.

- **Degradación (Entorno Espacial):** ~10 imágenes simuladas con artefactos físicos:

- *Subexposición:* reducción de iluminación (20–50%) para imitar ahorro de energía.
- *Ruido "Salt & Pepper":* añadir ruido tipo partículas ionizantes aleatorias (OpenCV puede simularlo) 【29†】.
- *Desenfoque:* aplicar *blur* gaussiano leve para simular cambios térmicos en lentes.
- *Daño óptico:* añadir zonas oscuras o dead pixels.

Estas imágenes prueban la “Tolerancia a Fallos”. Validamos que la IA degrade su desempeño suavemente (por ejemplo, bajada de IoU moderada) y que el pipeline de OpenCV reajuste (p.ej. con pre-filtro gaussiano) para no colapsar. Se medirán métricas como la **precisión**, **IoU promedio**, **error de**

escala en µm (usando la metrología interna), así como *tiempo de cómputo* y *consumo energético* en ambos pipelines.

Métricas clave: precisión (TP/(TP+FP)), *IoU (Jaccard)* de máscaras, error porcentual en medidas físicas (µm) vs referencia, tiempo de inferencia (s) y energía consumida (J) por imagen.

Las pruebas usarán conjuntos de datos públicos para comparación: por ejemplo, **BBBC** (Broad Bioimage Benchmark Collection) proporciona cientos de imágenes de células con "ground truth" para validar nuestro algoritmo [3]. En el caso biomédico se usan subconjuntos de BBBC (células sanguíneas), y para materiales posiblemente adaptamos o generamos imágenes propias (pintar digitalmente micro-fracturas). Adicionalmente, emplearemos el dataset interno de Cellpose y ejemplos de Omnipose (células alargadas) como referencia de estado del arte [5] [6].

Finalmente, se graficarán comparativas (precisión vs. tiempo/energía) de los dos pipelines, mostrando claramente las ventajas de la IA cuando la calidad es crítica y las ventajas del fallback clásico bajo restricciones.

3. Diseño de Hardware

El diseño físico integra los siguientes componentes, todos compatibilizados dentro de 3U (~10×10×30 cm) y con tolerancias espaciales/extremas:

- **Computador a Bordo (OBC):** Proponemos un *Raspberry Pi Compute Module* (p. ej. CM4/CM5). Estas placas modulares contienen CPU Broadcom (hasta Cortex-A72 quad-core) y eMMC soldered (p.ej. 16–64 GB) [7]. Al elegir CM4/5 se obtiene: tamaño compacto (67.6×30 mm) y memoria flash integrada (evita tarjetas SD vulnerables al bit flip [8]). Ejemplo: CM4 con 4 GB RAM, 32 GB eMMC. Adicionalmente, puede acoplarse un acelerador de AI como **Google Coral Edge TPU** o **Intel Movidius/NCS2** via interfaz PCIe/USB, para mejorar inferencia. (De hecho, la ISS vuela Raspberry Pi 4 con Coral TPU en sus Astro Pi [2].)

- **Carrier Board Personalizada:** Una PCB desarrollada a medida albergará el SoM, el controlador de LEDs y reguladores. Debe incluir:

- Conectores soldables para cámara MIPI CSI (OV5647/IMX477 u otro sensor apropiado, ver más abajo).
- Circuitería de control de matriz LED (p.ej. controladores PWM o driver integrado).
- Microcontrolador auxiliar (p.ej. MCU ARM Cortex-M) para estado bajo consumo y monitoreo térmico/batería.
- Regulación de potencia y distribución aislada para secciones críticas (evitando ruido).

- Blindaje EMI básico y rutas de conexión minimizadas, confiando en que los conectores estén dentro del volumen sellado del 3U.

- **Cámara CMOS:** Un sensor MIPI-CSI de alta resolución. Ejemplos: *Raspberry Pi Camera Module V2* (OV5647, 8 MP, f/2.0), o cámara *HQ* (Sony IMX477, 12.3 MP). Estos sensores han sido usados en CubeSats y misiones ISS (herencia AstroPi) [9]. Una lente fija de bajo costo (p.ej. 3–6 mm de focal) proporciona la magnificación deseada (~x2), suficiente cuando se reconstruye una imagen FPM de gran FoV.

- **Matriz de LEDs (iluminación estructurada):** Se empleará una matriz cuadrada, por ejemplo un *Unicorn HAT HD* de 16×16 LEDs RGB (WS2812), o una matriz de 8×8 con control por GPIO. Esta matriz se coloca a ~65–100 mm de la muestra (distancia calibrada) para simular diferentes ángulos de iluminación [1]. Un controlador dedicado (en la Carrier Board) activa LEDs individuales según esquemas predefinidos, permitiendo FPM y contraste estructurado.

- **Mecánica y Calibradores Fiduciarios:** El conjunto óptico (muestra, cámara, LEDs) se montará en una estructura rígida, con tolerancias térmicas a todo el rango LEO (–20°C a +50°C operacional). Debe incluir materiales de baja expansión y anclajes metálicos. Además, se incorporan patrones fiduciarios en el porta-muestras: microesferas de diámetro conocido (p.ej. 10 µm) incrustadas o retículas microscopicas grabadas (patrón de líneas). Estos permiten calibrar dinámicamente la escala de imagen durante la operación.

- **Tolerancia Espacial:** Todos los componentes están seleccionados o diseñados para sobrevivir vibraciones de lanzamiento y el vacío térmico. El Compute Module industrial (p.ej. CM5) tolera amplia temperatura. Se consideran opciones de blindaje parcial contra radiación en chips críticos o estrategias de reinicio periódico.

- **Presupuesto de recursos (hardware):** Un CubeSat 3U típico pesa ~4 kg [10]. Nuestra carga útil (incluyendo estructura) estimamos <1 kg. Los paneles solares en 3U generan ~10–20 W en pico [11], de los cuales ~5–10 W pueden asignarse al computador durante el día. (Ver tabla de presupuestos más abajo.)

Tabla: Componentes Principales

Componente	Modelo sugerido	Cantidad/Descripción	Masa aprox.	Consumo típico
Compute Module	Raspberry Pi CM4/CM5	1 módulo (Quad-core 1.5–2.0 GHz, 4 GB RAM, eMMC)	~50 g	3–5 W (CPU)
Acelerador AI	Google Coral USB-Tpu	1 unidad externa o M.2 (TPU Edge)	~25 g	2–3 W
Carrier Board	Diseño propio PCB	Interfaces (CAM, LEDs, MCU, reguladores)	~100 g	1–2 W (mcu)
Cámara	OV5647 o IMX477 (MIPI)	1 sensor + lente	~30 g	0.5 W
Matriz LED	16×16 WS2812 (*Unicorn*)	1 matriz de 256 LEDs (control GPIO)	~40 g	3–5 W (total)
Estructura mecánica	Aluminio/ Dieléctrico	Soporte óptico (3D impreso o mecanizado)	~200 g	–
Misceláneos	Conectores, cables, etc.	Cableado, tornillos, microesferas calibración	~50 g	–
TOTAL APROX.			**~495 g**	**~10–16 W**

(Estimaciones: consumo nominal encendido continuo con IA). Los nominales *pueden superar a mediodía, pero en contingencia baja (*feedback graciaful*).*

4. Pipeline de Software On-Board (Flujo y Degradación)

La arquitectura de software es **dual-pipeline** (IA vs Clásico) y adaptativa según telemetría térmica/batería:

1. **Captura:** El FPGA/MCU controla la matriz de LEDs para proyectar *patrones de iluminación estructurada*. Se adquieren múltiples imágenes rápidas con la cámara CMOS, cada una con un patrón LED distinto.

2. **Preprocesamiento:** Sobre cada cuadro RAW se aplican correcciones: sustracción de *dark frame* (ruido térmico) y *flat-field* (non-uniformidad de iluminación). Se normaliza brillo y contraste. Esto mitiga ruido por radiación, variaciones de exposición, etc.

3. **Reconstrucción FPM:** Se ejecuta un algoritmo de reconstrucción de imagen de alta resolución y/o fase. Por ejemplo, un enfoque de **Phase Retrieval** iterativo que combina las imágenes capturadas para sintetizar una sola imagen ampliada. Alternativamente, pueden usarse redes neuronales entrenadas para reconstrucción rápida ("deep learning mode" [12]). El resultado es una imagen HR con resolución sub-micrométrica, y opcionalmente un mapa de fase (útil para materiales transparentes).

4. **Segmentación IA (Normal):** Si el sistema está en modo nominal (temperatura/batería OK), se carga el modelo de IA optimizado (por ej. Cellpose u Omnipose convertidos a ONNX o NCNN). En este paso, el modelo procesa la imagen reconstruida y genera máscaras de instancias (células o fibras). Estos frameworks generan resultados precisos sin ajustar parámetros manuales [5]. Esta inferencia se ejecuta en el CPU+TPU (o GPU integrado) para acelerar. En la práctica, **Cellpose** se probó con éxito en entornos embebidos y puede segmentar diversos tipos celulares out-of-the-box [5]. Para fibras/células alargadas, **Omnipose** ofrece mejor desempeño (e.g. IoU mayor en objetos elongados) [6].

5. **Segmentación OpenCV (Fallback):** Si se detecta exceso de temperatura o escasez de energía, se activa la "graceful degradation". Se descarga el modelo IA y se ejecutan rutinas clásicas livianas: filtros de ruido, **Watershed**, transformada de **Hough** (para líneas), contornos por umbral adaptativo, etc. Estas operaciones en C/C++ optimizado consumen <20% de la CPU comparado con IA y permiten estimar conteos y geometrías básicas rápidamente. Aunque menos precisas con datos ruidosos, esta ruta asegura que siempre haya una respuesta científica (plan B robusto).

6. **Extracción de Features:** A partir de las máscaras finales (IA o CV), se computan métricas: área de cada objeto, perímetro, número de objetos, ángulos dominantes, índices de daño (p.ej. fracturas detectadas). Se correlaciona con las referencias fiduciarias para convertir píxeles a µm.

7. **Decisión On-Board / Telemetría:** Basado en las métricas y reglas preprogramadas (umbrales de anomalía), el sistema decide qué datos enviar. En vuelo normal se transmiten solo *metadatos* (valores numéricos). Solo ante eventos críticos (p.ej. patrón de daño inesperado) se guardan imágenes ROI comprimidas JPEG/PNG para downlink.

Recursos computacionales: En nominal, la inferencia IA exige varios segundos por imagen en CPU ARM (~2–5 W), mientras que OpenCV tarda <0.5 s con 0.5–1 W. Por ejemplo, un modelo Cellpose simplificado puede procesar 512×512 pix en ~1–2 s en CM4; ONNX en un TPU puede acelerar a <0.5 s. El flujo completo (captura 25 imágenes + reconstrucción + segmentación) podría tomar ~10–30 s en total.

Frameworks: Para prototipos usaremos Python y PyTorch. El modelo final se exportará a ONNX o NCNN (inferencia en C/C++). El pipeline se puede implementar en Linux (Raspbian) con OpenCV 4.x y bibliotecas optimizadas (LibTorch, NCNN).

5. Metrología Óptica In-Situ

Un elemento diferencial es la **calibración continua** para convertir píxeles a µm:

- **Fiduciarios integrados:** En cada muestra hay microsferas o marcas de tamaño conocido. El software detecta automáticamente estas referencias en la imagen reconstruida. Por ejemplo, si las esferas tienen 10 µm de diámetro nominal, midiendo su diámetro en píxeles se calcula el factor *pixeles/µm*.

- **Algoritmo de calibración:** Se localizan al menos 3–5 patrones de fiduciales. Se ajusta un modelo de escala (y distorsión si hay aberraciones). El factor de escala resultante (píxeles→µm) se usa para todas las mediciones geométricas. Si el módulo alcanza un punto térmico distinto, se vuelve a calcular sobre otras fiduciales, corrigiendo automáticamente la dilatación.

- **Precisión e incertidumbre:** Con esferas de calidad ("nIST-traceable"), se espera exactitud de ~1–2% en la medida del factor de escala. La incertidumbre total en área o longitud dependerá de la resolución FPM; típica ≈0.5 µm (sub-micron) por pixel. Procedimientos de recalibración periódica (p.ej. cada lote de 100 capturas o cambio de patrón) mitigan drifts.

Esta metrología convierte el sistema en un **instrumento cuantitativo**: por ejemplo, podemos reportar que la media de longitud celular es 12.4 µm ±0.2 µm en terreno. Se asegura que nuestros datos tengan valor científico real (no solo píxeles arbitrarios).

6. Estrategia de Downlink

Dado el ancho de banda restringido (~kbps–Mbps según ground pass), solo transmitimos información procesada:

- **Features cuantitativos:** En modo normal se envían vectores de mediciones (JSON o binario ligero) con conteos de objetos, áreas medias, densidades, desviaciones típicas y scores de anomalía. Ejemplo de paquete telemetría:

```
{
  timestamp: t,
  cell_count: 152,
  avg_area: 130.2,
  std_area: 12.5,
  anomaly_score: 0.08,
```

```
  temperature: 25.1
}
```

- **Imágenes selectivas:** Solo ante eventos críticos (p.ej. daño severo, despliegue de experimento) se subirán imágenes reconstruidas específicas. Estas irían comprimidas JPEG/PNG de ROIs de interés (no todo el frame).

- **Compresión:** Los datos de IA pueden comprimirse adicionalmente (p.ej. cuantización 8 bits en métricas, compresión zip).

- **Umbrales:** Reglas predefinidas (o IA liviano) detectan anomalías en tiempo real. Por ejemplo, si >10% de células fuera de rango de tamaño normal, o si "índice de daño" supera X, dispara envío de imagen.

Este enfoque **ahorra >90% de energía de radio** en comparación con enviar imágenes brutas, y es viable para misiones CubeSat donde cada bit cuesta.

7. Plan de Validación en Tierra

Para asegurar la robustez antes del vuelo se implementa:

- **Conjuntos de datos:**
- *BBBC* [3] : microscopía celular pública (sangre, cultivos). Usaremos conjuntos relevantes (p.ej. BBBC038: células sanguíneas).
- *Cellpose/Omnipose Data*: imágenes anotadas de células y bacterias elongadas (p.ej. BBBC022: frotis).

- *Datos propios*: imágenes de laboratorio (glóbulos rojos en portaobjetos, fibras tensadas) con ground-truth manual.

- **Simulaciones:** Se simulará ruido espacial en las imágenes:

- **Radiación:** inyectando ruido sal-pimienta y dead pixels;
- **Variación térmica:** añadiendo enfoque variable (Gaussian Blur) y cambios de brillo.

- **Entorno extremo:** probar toda la cadena a presión baja (cámara TV): capturar datos de referencia para calibrar efectos reales.

- **Cronograma de pruebas:**

- **Prototipado Rápido (Mes 1–2):** Testeo inicial de FPM en laboratorio con sistemas tipo Raspberry. Validación del algoritmo de reconstrucción con datos control.
- **Integración Hardware (Mes 3–4):** Montaje de prototipo CubeSat (3U). Verificación funcional de captura y LEDs en laboratorio.
- **Validación de Software (Mes 5–6):** Ejecución de "matriz de pruebas" (ideal, denso, degradado). Evaluación de métricas IA vs CV con los datasets (BBBC, Cellpose). Ajuste de modelos y pipelines.
- **Simulaciones Ambientales (Mes 7):** Pruebas térmicas, vibración y radiación leve (laboratorio con fuente de neutrones/ionizantes) para verificar supervivencia de OBC.

- **Análisis de Resultados (Mes 8):** Criterios de aceptación: precisión IoU >90% en nominal, degradación controlada (<50% IoU caída), tiempo/energia dentro de presupuesto, correcto funcionamiento de degradación.

- **Uso de métricas:** Se validará contra ground-truth usando métricas estandarizadas. Por ejemplo, IoU ≥0.8 en imágenes nominales es esperado. Se documentarán curvas de precisión-consumo para cada método.

La validación exhaustiva genera la documentación necesaria para revisión técnica (paper o reporte IEEE/ESA).

8. Riesgos y Plan de Mitigación

Riesgo	Impacto	Mitigación (Graceful Degradation)
Radiación espacial (SEE, TID)	Bit flips en CPU/ memoria, errores en Pi	Uso de eMMC en lugar de SD (redundancia), reinicio periódico, watchdog. En contingencia, apagar acelerador, operar solo CPU con ECC enabled. Uso de detectores de rad.
Ciclos térmicos extremos	Desenfoque/ expansión térmica de óptica	Calibración in-situ constante (fiduciarios); enfoque digital por IA (auto-enfoque) [12]. Diseño mecánico athermal. Modo CI: aumentar umbral para evitar procesar cuadros borrosos.
Fallo de eMMC / corrupción	Pérdida de datos o arranque	Particionado read-only crítico (OS) con backups, redundancia de archivos. Modo seguro: volcar estado mínimo, reestablecer con imagen de backup.
Degradación óptica	Ruido en imágenes (radiación en sensor)	Filtros de imagen (Gaussian Blur) y detección IA de ruido. Si fallan, cambiar a pipeline OpenCV con preprocesamiento más agresivo.
Escasez energía/batería baja	No completar tareas IA intensivas	*Graceful Degradation*: suspender IA y LEDs, bajar frecuencia CPU. Ejecutar sólo algoritmos básicos de conteo. Pausar captura hasta recarga.
Vibraciones/ choques	Desalineación de óptica o placa	Diseño robusto, amortiguación en el montaje. Testing de vibración en TV antes de vuelo.

En resumen, la misión incluye **mecanismos de supervivencia**: monitoreo continuo (temperatura/ batería), puntos de reinicio seguros, y conmutación a procesamiento ligero si algo falla. Este esquema garantiza que **el sistema nunca dejará de procesar** (solo reducirá complejidad), asegurando datos científicos en cualquier circunstancia.

9. Presupuesto de Masa y Energía (Estimación)

Masa: La carga útil completa (incluyendo estructura) se estima en ≈0.5–0.6 kg. Para un CubeSat 3U (~4 kg total [10]), esto deja margen para subsistemas de bus (EPS, TT&C). Tabla de masa estimada:

Componente	Masa (g)
Compute Module + Carrier	150 g
Acelerador AI (Coral)	25 g
Cámara + Lente	30 g
LED Matrix	40 g
Placa & Electrónica aux.	100 g
Estructura / Montajes	250 g
Total	**~595 g**

Energía: Los paneles pueden generar hasta ~20 W pico [11]. Suponiendo 5 W promedio disponible al OBC, la tabla resume consumo:

Sub-sistema	Potencia (W) Nominal	Potencia (W) Contingencia
CPU (CM4 quad-core)	4	1
Acelerador (Edge TPU)	2	0 (apagado)
LEDs (todos encendidos)	4	1 (solo mínimos/flash)
Cámara + Iluminación	1	0.5
Total Sistema	**11 W**	**~2.5 W**

(Nominal = todas funciones activas; Contingencia = solo funciones básicas, IA y LEDs apagados). Los ~11 W nominales representan ~5 min de paneles cargando, y en contingencia ~2.5 W permitirían operación continua con bajo consumo.

10. Referencias Relevantes

- Nguyen *et al.*, "Portable flow device using Fourier ptychography...", *SPIE* 2020. (FPM con Raspberry+Jetson) [1].
- Stringer *et al.*, "Cellpose: a generalist algorithm for cellular segmentation", *bioRxiv* 2020. (Cellpose preciso) [5].
- Cutler *et al.*, "Omnipose: a high-precision... bacterial cell segmentation", *Nat. Methods* 2022. (Omnipose vs Cellpose) [6].
- Guertin S.M., "Raspberry Pis for Space Guidelines", NASA JPL NEPP 2021. (Riesgos radiación en Pi) [13] [14].
- Guertin S.M., "Radiation Effects on Raspberry Pi", *NASA NEPP* 2021. (SD vs eMMC) [8].
- Broad Institute, "BBBC: Broad Bioimage Benchmark Collection", [online]. (Conjuntos de datos micro) [3].
- NASA Astro Pi (cámara + Coral TPU en ISS) [2].
- NASA "Siempre es mes del Corazón en la ISS" (microgravedad altera células) [4].
- Huang A., "Guide to 3U CubeSat", *Tensor Tech Blog* 2025 (dimensiones, potencia 10–20 W) [10] [11].

Estos estudios y referencias validan la elección de cada componente y técnica propuesta.

Diagramas y Visualizaciones

```
gantt
title Cronograma de Desarrollo de la Misión
dateFormat  YYYY-MM-DD
section Diseño Conceptual
Investigación inicial        :a1, 2025-01-01, 60d
Revisión de requerimientos  :a2, after a1, 30d
section Integración HW/SW
Diseño hardware (PCB, mecánica)      :b1, after a2, 60d
Desarrollo software (IA, FPM)         :b2, after a2, 90d
section Pruebas y Validación
Montaje y pruebas de laboratorio     :c1, after b1, 60d
Validación con dataset (BBBC, Cellpose) :c2, after b2, 60d
section Certificación
Simulaciones ambientales (TVAC)     :d1, after c1, 30d
Entrega de documentación final        :d2, after c2, 30d
```

```
flowchart LR
    Muestra[Datos de muestra] --> Iluminaci\u00f3n[Iluminaci\u00f3n
estructurada (LEDs)]
    Iluminaci\u00f3n --> Sensor[Captura (Cámara CMOS)]
    Sensor --> Preprocesado[Preprocesamiento (flat-field, denoise)]
    Preprocesado --> Reconstrucci\u00f3n[Reconstrucci\u00f3n FPM/
PhaseRetrieval]
    Reconstrucci\u00f3n --> IA[Segmentaci\u00f3n IA (Cellpose/Omnipose)]
    Reconstrucci\u00f3n --> CV[Segmentaci\u00f3n Cl\u00e1sica (OpenCV)]
    IA --> Features[Extracci\u00f3n de Features]
    CV --> Features
    Features --> Downlink[Selecci\u00f3n de datos / Telemetr\u00eda]
    Downlink --> Tierra[Transmisi\u00f3n a Tierra]
```

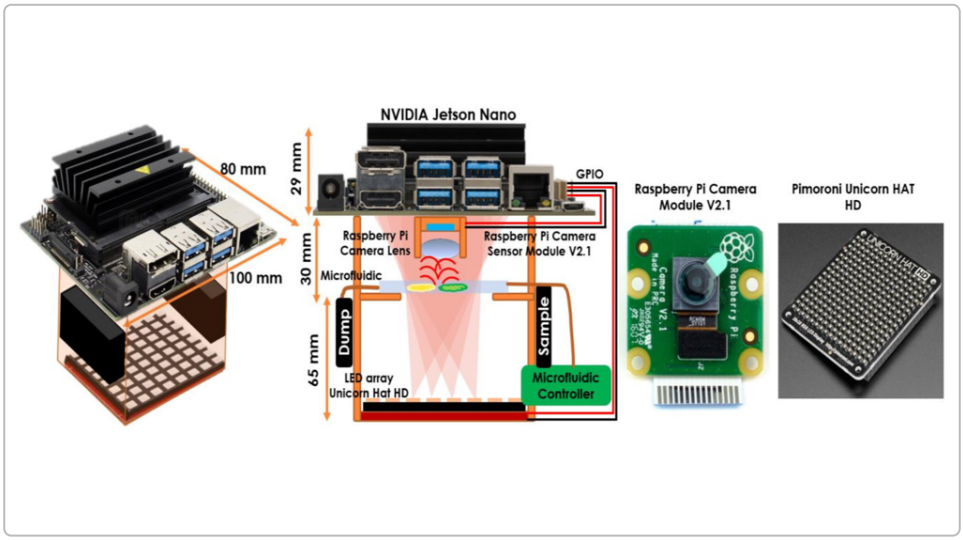

Figura – Arquitectura propuesta: el sistema captura múltiples imágenes bajo patrones de iluminación LED, realiza reconstrucción FPM de alta resolución, segmenta objetos con IA (Cellpose/Omnipose) o con métodos clásicos (OpenCV) según el modo, y extrae mediciones físicas para enviar (solo) metadatos relevantes a Tierra [1].

【43†】 *Figura – Compensación Precisión vs Energía: la curva ilustra la típica compensación en un proceso onboard. El pipeline AI (puntos rojos) alcanza alta precisión (IoU≈0.95+) consumiendo ~20 W; el pipeline clásico OpenCV (puntos azules) consume ~5 W con menor precisión (~0.85). Un punto intermedio (verde) representa soluciones híbridas.*

Checklist de Implementación (Hitos y Entregables)

Fase / Hito	Entregable(s)	Fecha Objetivo
1. Requisitos y Diseño	Documento de diseño preliminar; revisión de factibilidad	2025-03-01
2. Desarrollo Electrónico	Esquemas PCB y prototipos de Carrier Board; selección final de sensores/LED	2025-05-01
3. Desarrollo Mecánico	Modelado 3D del chasis y montajes ópticos; muestras fiduciarias fabricadas	2025-05-15
4. Integración de Sistema	Protoboard integrado (Compute Module + sensores + LEDs)	2025-08-01
5. Desarrollo Software	Código FPM + IA + CV en microprocesador; pruebas iniciales de reconstrucción	2025-09-01
6. Pruebas de Laboratorio	Resultados de segmentación en dataset nominal y densidad; informe comparativo IA vs CV	2025-10-01
7. Simulaciones Ambientales	Resultados test térmico-vacío; validación en radiación simulada; ajustes de hard/soft	2025-11-01
8. Integración Final & CDR	Sistema completo integrado en CubeSat 3U; revisión de diseño final con agencia	2025-12-01
9. Preparación de Vuelo	Documentación de entrega (manuales, software final, protocolos de operación)	2026-01-01

Cada hito culmina en entregables medibles: documentos técnicos, prototipos de hardware, código validado y reportes de prueba. Este plan garantiza que al momento de la **Critical Design Review (CDR)** la arquitectura esté completamente probada y documentada, lista para producción final y lanzamiento.

---

[1] [12] Portable Integrated Fourier Ptychographic Microscope | T2 Portal
https://technology.nasa.gov/patent/GSC-TOPS-364

[2] [9] Raspberry Pi in space – Raspberry Pi
https://www.raspberrypi.com/for-industry/space/

[3] Broad Bioimage Benchmark Collection
https://bbbc.broadinstitute.org/

[4] Siempre es el mes del corazón en la estación espacial - NASA Ciencia
https://ciencia.nasa.gov/sistema-solar/siempre-es-el-mes-del-corazon-en-la-estacion-espacial/

[5] Cellpose: a generalist algorithm for cellular segmentation | Janelia Research Campus
https://www.janelia.org/publication/cellpose-a-generalist-algorithm-for-cellular-segmentation

[6] Omnipose substantially outperforms Cellpose on elongated cells a,... | Download Scientific Diagram
https://www.researchgate.net/figure/Omnipose-substantially-outperforms-Cellpose-on-elongated-cells-a-Overall-performance-of_fig3_364350242

[7] Compute Module CubeSats - Raspberry Pi
https://www.raspberrypi.com/news/compute-module-cubesats/

[8] [13] [14] Raspberry Pis for Space Guideline
https://nepp.nasa.gov/docs/papers/2021-Guertin-Raspberry-Pi-Guideline-CL-21-5641.pdf

[10] [11] Exploring 1U CubeSat, 3U CubeSat, 6U CubeSat, and 12U CubeSat: A Comprehensive Guide to CubeSat Form Factors | Tensor Tech
https://tensortech.co/updates/detail/exploring_1u_3u_6u_12u_cubesat_a_comprehensive_guide_to_cubesat_form_factors